

Projet d'imagerie médicale

Spatially varying color distributions for interactive multilabel segmentation

Margot Barbet, Adèle Gillier, Victor Sanh

1 Introduction

Parce qu'elle permet d'extraire des zones d'intérêt, la segmentation a une place importante dans l'imagerie médicale. Elle permet en effet d'avoir une idée précise des contours de la zone que l'on souhaite étudier et donc d'avoir une meilleure connaissance de cette zone. Les opérations médicales requérant exactitude et précision, il est nécessaire d'être capable de segmenter correctement les zones d'intérêt. La segmentation interactive présente l'avantage de pouvoir préciser à l'algorithme la zone que l'on souhaite segmenter et lui permettre ainsi de se concentrer sur cette zone.

Nous avons étudié la méthode de segmentation multi-labels proposée par NIEUWENHUIS et CREMERS [3]. Nous nous sommes intéressés à l'influence des différents paramètres dans la modélisation en allant plus loin que l'article notamment sur l'influence de la quantité et la localisation des labels utilisateurs. Nous avons ensuite appliqué la méthode à des images médicales pour segmenter des lésions du cerveau ou encore des ventricules. Nous avons enfin réfléchi à une méthode nous permettant d'appliquer la segmentation proposée sans interaction de la part de l'utilisateur.

2 Le modèle

On s'intéresse ici à des segmentations d'objets ayant plusieurs couleurs, certaines proches des couleurs de l'arrière plan de l'image, et avec des illuminations différentes selon l'endroit de la photographie. C'est un cas particulièrement difficile pour la segmentation. La contribution principale de l'article de NIEUWENHUIS et CREMERS [3] est de modéliser la distribution de couleur en fonction de la localisation (et non plus constante sur toute l'image) par une approche Bayésienne. Leur modèle repose sur l'hypothèse que les couleurs des pixels sont indépendantes les unes des autres mais dépendantes de leur localisation dans l'image. Contrairement aux autres méthodes de segmentation interactive, les auteurs se proposent de modéliser conjointement l'information chromatique et spatiale des labels utilisateurs, et non pas uniquement une de ces deux informations.

2.1 Inférence Bayésienne basée sur la dépendance spatiale

On étudie ici une segmentation interactive, c'est-à-dire qu'un utilisateur indique les labels pour un certain nombre de pixels de l'image. On notera l'ensemble de ces labels $\{(I_{ij}, x_{ij})\}_{ij}$ où $i \in \{1, \dots, n\}$ est le numéro de la classe recherchée, $j \in \{1, \dots, m_i\}$ le numéro du label connu dans la classe i ayant m_i labels utilisateurs, et enfin I_{ij} l'intensité du j -ème point de la i -ème classe qui se situe sur le pixel à la position x_{ij} .

On note $I : \Omega \subset \mathbb{R}^2 \rightarrow \mathbb{R}^d$ la fonction d'intensité en chaque point de l'image. La segmentation peut se formuler comme la recherche de n régions disjointes $(\Omega_i)_{i=1..n}$, telles que le domaine de l'image Ω vérifie $\Omega = \bigcup_{i=1}^n \Omega_i$, où chaque région Ω_i regroupe les pixels de label i . On notera θ_i la fonction indicatrice associée, i.e. $\theta_i(x) = 1$ si et seulement si $x \in \Omega_i$.

Résoudre le problème de segmentation par une approche Bayésienne revient à chercher la segmentation $\theta = (\theta_i)_{i=1..n}$ qui maximise la probabilité conditionnelle suivante :

$$\operatorname{argmax}_{\theta} \mathcal{P}(\theta|I) = \operatorname{argmax}_{\theta} \mathcal{P}(I|\theta)\mathcal{P}(\theta) \quad (1)$$

On suppose dans l'article que les intensités des pixels sont indépendantes les unes des autres, et que la distribution de couleur du pixel x ne dépend pas de la classe de ses voisins, mais qu'elle est par contre dépendante de sa localisation. Cette approche de dépendance spatiale se distingue de beaucoup de méthodes classiques de segmentation. En effet, on suppose ici, que l'illumination varie selon la localisation de l'image, et que donc l'intensité en un pixel dépend de sa position. L'hypothèse d'indépendance des intensités entre elles nous permet de formuler la probabilité conditionnelle de la manière suivante :

$$\mathcal{P}(I|\theta) = \prod_{i=1}^n \prod_{x \in \Omega_i} (\mathcal{P}(I(x), x|\theta_i(x) = 1))^{dx} \quad (2)$$

La recherche des labels en chaque pixel non annotés se base sur les labels fournis par l'utilisateur en entrée. NIEUWENHUIS et CREMERS ont proposé d'estimer cette dépendance aux labels utilisateurs par un modèle de noyaux gaussiens. Par cette méthode, on obtient l'estimateur suivant :

$$\hat{\mathcal{P}}(I(x), x|\theta_i(x) = 1) = \frac{1}{m_i} \sum_{j=1}^{m_i} k_{\rho_i}(x - x_{ij}) k_{\sigma}(I - I_{ij}) \quad (3)$$

avec $k_{\rho}(x) = \frac{1}{\sqrt{2\pi\rho^2}} e^{-\frac{x^2}{2\rho^2}}$. L'intensité en un point dépend des intensités et des positions des labels utilisateurs dans un voisinage, ce voisinage étant défini par les noyaux gaussiens et leurs paramètres.

Bien que les intensités des labels utilisateurs I_{ij} peuvent être considérées comme indépendantes, ce n'est pas le cas en pratique de leurs coordonnées x_{ij} . En effet, les labels sont le plus souvent des traits tracés pas l'utilisateur. Pour prendre en compte cet effet NIEUWENHUIS et CREMERS ont décidé de choisir un noyau ayant une profondeur $\rho_i(x)$ dépendant de la distance du pixel x au label utilisateur le plus proche, en posant :

$$\rho_i(x) = \min_{j=1..m_i} \alpha |x - x_{ij}| \quad (4)$$

Ainsi, plus le point est loin des labels utilisateurs, plus la région dans laquelle ces labels sont pris en compte est large, comme le montre la figure 1.




FIGURE 1: Influence de la distance aux labels utilisateurs "rouges" sur la taille du noyau k_{ρ_i}

Enfin la probabilité à priori $\mathcal{P}(\theta)$ est modélisée comme proportionnelle aux périmètres des régions segmentées, de manière à favoriser les régions de périmètre faible, et donc plus "lisse". On pose donc :

$$\mathcal{P}(\theta) \propto \exp - \frac{1}{2} \sum_{i=1}^n \operatorname{Per}_g(\Omega_i) \quad (5)$$

où $\operatorname{Per}_g(\Omega_i)$ est une mesure du périmètre de la région de label i , Ω_i .

2.2 Minimisation d'un problème convexe

En passant par la recherche d'un maximum de log-vraisemblance, le problème 1 peut alors se reformuler comme la minimisation de l'énergie \mathcal{E} , donnée par :

$$\mathcal{E}(\Omega_1, \dots, \Omega_n) = \frac{1}{2} \sum_{i=1}^n \operatorname{Per}_g(\Omega_i) - \lambda \sum_{i=1}^n \int_{\Omega_i} \log(\hat{\mathcal{P}}(I(x), x|\theta_i(x) = 1)) dx \quad (6)$$

Le premier terme de l'énergie représente la probabilité à priori $\mathcal{P}(\theta)$ et le second est l'estimateur de la probabilité conditionnelle que nous venons de construire. Ce second terme traduit l'adéquation du modèle à l'image (maximisation de l'adéquation à l'image) tandis que le premier terme peut être vu comme un terme de régularisation (minimisation du périmètre). Le paramètre λ pondère l'influence de la régularisation et la fidélité aux données, et empêche le sur-apprentissage de la segmentation.

En utilisant les variables duales $\xi_i \in C_c^1(\Omega, \mathbb{R}^2)$ pour prendre en compte la contrainte $\sum_{i=1}^n \theta_i(x) = 1$, le problème de minimisation de l'énergie \mathcal{E} peut se reformuler ainsi :

$$\min_{\theta} \mathcal{E}(\theta) = \min_{\theta} \sup_{\xi} \left\{ - \sum_{i=1}^n \lambda \int_{\Omega} \theta_i \log(\hat{\mathcal{P}}(I(x), x | \theta_i(x) = 1)) dx - \int_{\Omega} \theta_i \operatorname{div} \xi_i dx \right\} \quad (7)$$

En relaxant l'hypothèse $\theta_i(x) \in \{0, 1\}$ par $\theta_i(x) \in [0, 1]$, le problème d'optimisation convexe 7 peut se résoudre numériquement à l'aide d'un algorithme primal-dual : on minimise d'un côté l'énergie primale tout en maximisant l'énergie duale en même temps. Cela se fait par une méthode de gradient projetée, qui effectue à chaque itération alternativement une descente de gradient par rapport à θ et une "montée de gradient" par rapport à la variable ξ . Enfin on effectue un seuillage sur les valeurs de θ_i pour les rendre binaires. Cette méthode fournit la solution optimale dans le cas d'une segmentation à deux classes et une solution approchée dans le cas général (la différence est bornée théoriquement), et permet d'aboutir à une segmentation.


3 Influence des paramètres

Pour étudier l'influence des différents paramètres, nous nous sommes basés sur des images segmentées de la base de données de Berkeley [2]. Nous avons choisi cette base de données car celle-ci est adaptée au problème de la segmentation puisqu'elle contient les vérités terrains. En outre, à l'inverse des images médicales, les images de cette base de données contiennent de nombreuses couleurs et sont donc plus adaptées à l'étude des paramètres puisque la couleur rajoute une difficulté à la segmentation. Ces images sont ainsi plus difficiles à segmenter que des images médicales, ce qui explique que nous ayons basé notre étude sur celles-ci.


3.1 Les paramètres σ , α et λ

Le paramètre σ de la gaussienne estimant l'impact des couleurs des labels utilisateurs

La variance du noyau sur la couleur σ précise la façon dont la segmentation va dépendre de la couleur. Si σ est trop petit, seules les couleurs des pixels labélisés très proches de la couleur du pixel non labélisé considéré ont une influence, et plus un pixel labélisé a une couleur similaire, plus la probabilité que le pixel considéré appartienne à la même classe est forte. Au contraire, plus σ est grand, et moins la couleur des pixels labélisés a de l'importance. Les poids dans la gaussienne sont de plus en plus faibles et de moins en moins discriminants. Dans le cas extrême $\sigma \rightarrow +\infty$, tous les labels utilisateurs ont un impact uniforme et faible (en terme de couleur) sur tous les points de l'image. Dans ce cas, la segmentation est purement basée sur la distance aux labels utilisateurs, on obtient alors des cellules de Voronoï. Ce cas est illustré par la figure 2c. La figure 2 illustre, à α et λ fixés, l'importante variation dans la segmentation en fonction de σ .



(a) Labels utilisateurs sur l'image



(b) Segmentation avec $\sigma = 0.5$ (Avg Dice = 0.98)



(c) Segmentation avec $\sigma = 100$ (Avg Dice = 0.57)

FIGURE 2: Segmentations en fonction de σ

Le facteur de distance aux labels utilisateurs α

Le facteur de distance α détermine l'influence spatiale des traits des utilisateurs en entrée, comme illustrée par la figure 3. Ce paramètre va permettre de déterminer à quel point la distance aux labels utilisateurs les plus proches a une influence. Plus le paramètre α est petit, plus l'information spatiale apportée par le label utilisateur est prise en compte localement. Au contraire, plus α est grand, plus les points éloignés de ce label pourront bénéficier de cette information spatiale, mais l'information devient moins discriminante. Dans le cas extrême $\alpha \rightarrow 0$, seuls les labels utilisateurs voisins directs du point considéré sont pris en compte. A l'inverse, dans le cas extrême $\alpha \rightarrow +\infty$, tous les points de l'image seront impactés uniformément par leurs distances aux labels utilisateurs. Les labels utilisateurs n'apportent donc plus aucune information spatiale, nous sommes alors dans le cas d'une approche purement basée sur la couleur. La figure 3c illustre bien ce fait puisque nous constatons que les zones obtenues sont homogènes en couleur : le haut du pelage est confondu avec les icebergs de l'arrière plan et le bas du pelage, les ailes et les pattes plus foncées sont confondues avec le rocher.




FIGURE 3: Segmentations en fonction de α

Le paramètre de régularisation λ

Le paramètre de régularisation λ agit sur le caractère lisse du contour. Plus λ est petit, plus les formes des parties segmentées sont lisses. Mathématiquement, cela s'explique par la formule de minimisation de l'énergie (6). En effet, plus λ est petit dans cette équation, plus le terme associé au périmètre de la forme est important. Ainsi, plus λ est petit plus minimiser l'énergie revient à minimiser le périmètre, c'est-à-dire, à rendre la forme de plus en plus lisse. La figure 4 montre bien l'impact de ce paramètre puisque nous voyons que dans le deuxième cas, les contours sont bien plus lisses et respectent moins les contours des pétales des fleurs. Cependant, si λ est trop grand, cela peut créer des zones isolées telles que celle présente dans la figure 4b : les labels utilisateurs représentent mal la variation de couleur au sein de la classe des fleurs (le centre du pistil a une couleur similaire à l'arrière plan).




FIGURE 4: Différentes segmentations en fonction du paramètre λ

3.2 Les labels utilisateurs

L'article n'évoquant que qualitativement l'impact du nombre et de la répartition des labels utilisateurs sur la segmentation, nous avons décidé d'étudier cet impact de manière plus quantitative.


Méthode employée

Nous voulons étudier l'influence du nombre et de la localisation des labels utilisateurs sur la qualité de la segmentation. Pour quantifier la qualité d'une segmentation, nous disposons de la vérité terrain et comparons la segmentation obtenue à la vérité terrain à travers le score moyen de Dice ($\frac{1}{n} \sum_{i=1}^n \frac{2|GT_i \cap E_i|}{|GT_i| + |E_i|}$ où GT_i et E_i désignent l'ensemble des points appartenant à la classe i dans la vérité terrain et la segmentation estimée). Nous avons utilisé les données de segmentation de la Segmentation Berkeley Database [2] pour nous comparer à la vérité terrain.

Le procédé employé est le suivant : en extrayant les contours de la vérité terrain, nous tirons aléatoirement sans remise N pixels à distance d du contour situés dans l'objet que l'on cherche à segmenter (classe arrière-plan) et N pixels à distance d du contour n'appartenant pas à l'objet. La distance au contour utilisée est la distance de Manhattan. Ces points choisis aléatoirement et labellisés en fonction de la vérité terrain sont donnés à l'algorithme comme des labels utilisateurs. Pour chaque paire de valeurs (N, d) , nous moyennons sur 100 simulations le score moyen de Dice obtenu.

Résultats

La figure 5 représente les scores moyens de Dice calculés sur différentes images en fonction de la distance au contour d et du nombre de labels utilisateurs N . Le nombre de labels utilisateurs a peu d'influence tant qu'il est assez grand, ici supérieur à 500. La position des labels utilisateurs par rapport à la frontière entre les deux classes Ω_0 et Ω_1 a par contre beaucoup d'importance comme le montre la courbe 5a : lorsque les labels sont trop proches de la frontière des pixels mal segmentés apparaissent loin de cette frontière car ils sont à distance semblable des labels provenant des deux régions. Lorsque les labels sont trop loin de la frontière, l'algorithme a bien sûr plus de mal à estimer cette frontière. Vous pourrez trouver en annexe des images détaillant ces effets.



(a) Score moyen de Dice en fonction de la distance des labels utilisateurs au contour recherché d (b) Score moyen de Dice en fonction du nombre de labels utilisateurs N

FIGURE 5: Influence du nombre et de la distance des labels utilisateurs aux labels recherchés

4 Application aux images médicales


4.1 Le ventricule gauche

Nous nous sommes intéressés au cas de la segmentation du ventricule gauche du coeur. Pour cela, nous avons récupéré les données issues du *Left Ventricle Segmentation Challenge* [4]. Pour appliquer notre segmentation sur le ventricule gauche nous avons choisi de fixer les paramètres comme indiqué sur le tableau 1. Nous avons notamment choisi de fixer λ à 0.001 puisque les contours du ventricule sont très lisses. La figure 6 illustre ce que nous avons obtenu à l'aide de l'algorithme de segmentation. Nous remarquons que l'algorithme retrouve bien la forme du ventricule.


| σ | α | λ |
|----------|----------|-----------|
| 1.3 | 10 | 0.001 |

TABLE 1: Valeurs des paramètres pour la segmentation du ventricule


La vérité terrain associée à cette base de données est issue de la segmentation faite par un expert et est donc approchée. Ainsi, le score de Dice que nous avons obtenu, 0.92, est approximatif.



(a) Segmentation d'un expert sur le ventricule



(b) Labels utilisateurs sur le ventricule



(c) Segmentation obtenue par l'algorithme (Avg Dice = 0.92)


FIGURE 6: Segmentation du ventricule gauche

4.2 Des lésions du cerveau


Nous pouvons imaginer un chirurgien souhaitant obtenir une segmentation d'une lésion dans le cerveau d'un patient avant de procéder à l'opération. C'est pourquoi nous avons voulu appliquer notre algorithme à la segmentation de lésions du cerveau. Pour appliquer cette segmentation nous avons utilisé les paramètres présentés en table 2. Nous remarquons sur la figure 7c que l'algorithme a parfaitement été capable de segmenter la lésion que nous souhaitons étudier. Pour cela, il suffit que l'utilisateur, le chirurgien, trace quelques labels rapides sur les parties qui l'intéressent comme l'illustre la figure 7b. Nous remarquons cependant que l'algorithme ne segmente que la lésion principale où se situent les labels. Si l'utilisateur souhaite segmenter toutes les régions, celui-ci aura besoin de donner davantage de labels.

| σ | α | λ |
|----------|----------|-----------|
| 5 | 10 | 0.002 |


TABLE 2: Valeurs des paramètres pour la segmentation des lésions du cerveau



(a) Lésions sur le cerveau



(b) Labels utilisateurs sur une des lésions



(c) Segmentation obtenue par l'algorithme

FIGURE 7: Segmentation de la lésion du cerveau

5 Peut-on se passer des labels utilisateur en entrée ?

5.1 Le coût des labels utilisateur et comment s'en passer

Les labels ajoutés à la main par l'utilisateur peuvent représenter un coût important. Nous nous sommes alors interrogés sur la possibilité d'outrepasser ces entrées utilisateurs. Pour ce faire, nous avons eu l'idée d'effectuer un pré-traitement à l'image puis de donner en entrée à l'algorithme l'image pré-traitée. Le pré-traitement a pour but de segmenter une partie de l'image, sans sollicitation de l'utilisateur, pour obtenir des labels associés à chaque classe de la segmentation. Ces labels sont alors les entrées de l'algorithme qui les utilisera en tant que labels utilisateurs pour effectuer la segmentation finale.

5.2 Le pré-traitement par seuillage

Nous avons choisi d'effectuer le pré-traitement grâce à un algorithme de seuillage. La technique du seuillage consiste à segmenter une image en plusieurs classes en fonction de l'intensité de chaque pixel de l'image [1]. Il s'agit dans cette méthode de considérer un seuil d'intensité T et de séparer les pixels ayant une intensité inférieure à T des pixels ayant une intensité supérieure à T . Cette séparation définit les classes de la segmentation. Dans notre cas, l'algorithme semble d'autant plus légitime que nous travaillons sur des images médicales qui sont très souvent en nuance de gris. Sur des images telles que des radios d'os par exemple, le seuillage semble ainsi très adapté.

Le pré-traitement par seuillage que nous appliquons vise ainsi à segmenter l'image en trois classes en associant les labels -1, 0 et 1 à chacune des classes :

- les pixels de faible intensité, i.e. d'intensité inférieure à un seuil T_1 , sont associés à l'arrière-plan et se voient attribuer le label 0 ;
- les pixels de forte intensité, i.e. d'intensité supérieure à un seuil T_2 , sont associés au premier plan et se voient attribuer le label 1 ;
- les pixels ayant une intensité comprise entre les deux seuils T_1 et T_2 ne sont pas classifiés à partir du seuillage mais le seront par l'algorithme, on leur attribue alors le label -1.




FIGURE 8

La figure 8b représente l'étape de pré-traitement de la segmentation à partir du seuillage. En gris se trouvent les pixels identifiés comme étant de l'arrière-plan, en blanc les pixels identifiés comme étant du premier plan et en noir se trouvent les pixels ayant une intensité intermédiaire.

L'algorithme de segmentation prend en entrée les labels obtenus du seuillage et les considère tels que les labels utilisateurs pour sa segmentation. Son rôle est alors d'affiner la segmentation en classifiant les pixels de labels -1 en premier plan ou arrière-plan.

5.3 Résultats de cette méthode

La figure 8c montre les résultats que nous avons obtenus sur la main étudiée. Nous remarquons en premier lieu que le bout des doigts n'est pas reconnu par l'algorithme comme étant du premier plan. Cela s'explique par l'absence

de labels 1 autour des zones concernées (la variation de couleur est mal représentée par les seuillages). L'algorithme s'appuyant sur les couleurs et distances aux labels fournis, celui-ci classe ces zones comme étant de l'arrière-plan puisqu'elles sont trop éloignées des zones de label 1 (en distance et en couleur). De plus, l'intensité n'est pas uniforme au sein de l'image : l'intensité est plus forte dans le bas de l'image. Cela perturbe l'influence de la couleur dans la segmentation. De la même façon, la partie située entre les deux os du poignet est classifiée comme étant de l'os car elle est entourée de zones appartenant aux os et qu'elle est particulièrement lumineuse. Ainsi, pour des parties jugées complexes, nous aurions besoin davantage de labels d'où la nécessité de labels utilisateurs. Nous pouvons ainsi imaginer réaliser un premier pré-traitement par seuillage puis améliorer la segmentation obtenue à l'aide de nouveaux labels donnés par l'utilisateur. Il semble alors difficile d'utiliser l'algorithme proposé par NIEUWENHUIS et CREMERS en se passant totalement des labels utilisateurs, notamment pour des images avec des jeux d'intensité différents.

6 Conclusion

6.1 Opinion critique de l'article

Certains points et méthodes décrits dans l'article soulèvent notre attention et notre interrogation.

Tout d'abord, le modèle suppose l'indépendance des pixels : les couleurs des pixels sont indépendantes et la distribution de couleur en un pixel ne dépend pas de la classe de ses voisins. Ces hypothèses d'indépendance nous paraissent fortes et non vérifiées dans le cas réel où deux pixels voisins ont tendance à appartenir à la même classe et à avoir des distributions de couleurs similaires.

Par ailleurs, les auteurs concluent leur étude en affirmant que la qualité de la segmentation ne dépend pas vraiment de la quantité ou la localisation des labels utilisateurs. Cette affirmation nous paraît contre-intuitive : la distribution de couleur est estimée uniquement à partir des labels utilisateurs. Plus, le nombre de labels utilisateurs est important, plus la distribution de probabilité sera mieux estimée. La quantité de labels utilisateurs nous semble donc jouer un rôle dans la qualité de la segmentation. De plus, même si les auteurs précisent que tant que les labels utilisateurs représentent correctement la variation de couleur au sein d'une même classe, la localisation des labels utilisateurs n'a que peu d'influence sur la qualité de la segmentation. Cette affirmation n'est pas basée sur une étude quantitative. Nous avons donc essayé d'étudier quantitativement cet effet. Nos expérimentations suggèrent que la localisation des labels utilisateurs joue un rôle important dans la qualité de la segmentation.

Enfin, l'étude de l'influence des paramètres a montré la difficulté de choisir les différents paramètres du modèle (σ , α et λ), et que différentes valeurs de ces paramètres pouvaient mener à des segmentations de qualité drastiquement différente. Même si les auteurs proposent des valeurs moyennes qui semblent fonctionner de manière raisonnable sur un grand nombre d'images, nos expérimentations ont montré qu'il était raisonnable d'atteindre une segmentation de qualité supérieure avec les mêmes labels d'entrée. La structure du problème nous paraît être adaptée pour apprendre ces paramètres : en connaissant la vérité terrain, nous sommes capables d'estimer (par montée de gradient par exemple) le meilleur jeu de paramètres maximisant le score moyen de Dice (ou autre métrique exprimant la qualité d'une segmentation). Ainsi, il paraît plus raisonnable (mais plus coûteux) d'avoir un jeu de paramètres spécifique à une classe d'images (radiologie, IRM, etc.).

6.2 Résumé

Nous nous sommes intéressés au problème de segmentation interactive. La méthode proposée par NIEUWENHUIS et CREMERS se distingue par la modélisation de la dépendance spatiale de la segmentation aux labels utilisateurs et pas uniquement de la similarité chromatique. Prendre en compte cette dépendance spatiale est important car d'une part l'hypothèse d'indépendance spatiale des labels utilisateurs n'est pas en pratique vérifiée, et d'autre part, cela permet de modéliser des distributions de couleurs variant spatialement. Nous nous sommes concentrés sur la segmentation binaire.

Notre travail porte en premier lieu sur l'influence des paramètres du modèle, que nous avons étudié à partir des données de la base de segmentation de Berkeley. Nos expérimentations montrent que ces paramètres influent de manière drastique sur la qualité de la segmentation. Il serait intéressant dans un travail complémentaire d'approcher les paramètres optimaux de manière automatique.

D'autre part, ce point n'étant que peu abordé par les auteurs, nous nous sommes penchés sur l'influence des labels utilisateurs (quantité et localisation) sur la qualité de la segmentation. Pour cela, nous avons utilisé une méthode de Monte-Carlo pour estimer le score de Dice moyen pour un jeu de valeurs donné. Nos expérimentations montrent qu'il est important d'avoir une quantité suffisante de labels utilisateurs, mais qu'au dessus d'un certain nombre, rajouter des labels n'apporte pas d'amélioration significative. De plus, dans le cas optimal, les labels utilisateurs ne sont ni trop

loin, ni trop près de la frontière entre les deux classes : l'important est que les labels utilisateurs montrent correctement la variation de la couleur au sein d'une même classe.

Enfin, nous avons étendu la méthode proposée par les auteurs en essayant de se passer de l'interaction utilisateur. Sur des images médicales simples, nous avons utilisé une méthode de seuillage pour labeliser une partie de l'image et s'en servir comme labels utilisateurs. Nos expérimentations montrent que cette approche mérite d'être étudiée plus profondément. Les résultats sont encourageants mais imparfaits notamment car les seuillages capturent mal la variation de couleur au sein d'une même classe.

Références

- [1] Stefano Ferrari. Image segmentation. *Course material for course Image Processing I. The University of Milan*, 2011.
- [2] D. Martin, C. Fowlkes, D. Tal, and J. Malik. A database of human segmented natural images and its application to evaluating segmentation algorithms and measuring ecological statistics. In *Proc. 8th Int'l Conf. Computer Vision*, volume 2, pages 416–423, July 2001.
- [3] Claudia Nieuwenhuis and Daniel Cremers. Spatially varying color distributions for interactive multilabel segmentation. *IEEE transactions on pattern analysis and machine intelligence*, 35(5) :1234–1247, 2013.
- [4] P Radau, Y Lu, K Connelly, G Paul, AJ Dick, GA Wright, S Huang, J Liu, LC Lee, SK Venkatesh, et al. Cardiac mri left ventricle segmentation challenge, 2008.

Annexes

Répartition des tâches

Nous avons travaillé sur ce projet en un groupe de trois personnes : Adèle, Victor et Margot. Nous avons tous travaillé sur l'étude et la compréhension du modèle ainsi que sur l'influence des paramètres σ , α et λ . De plus, à l'exception de la figure 1, nous avons généré toutes les images de segmentation de ce rapport. L'étude de l'impact qualitatif du nombre et de la répartition des labels utilisateurs à travers la génération aléatoire des labels et le calcul du score de Dice a été réalisée par Adèle et Victor. Margot a étudié la possibilité de se passer des labels utilisateurs via le pré-traitement par seuillage et a appliqué le modèle aux images médicales.

L'ensemble des analyses que nous avons codées est disponible sur le dépôt *Git* de notre projet à l'adresse suivante https://github.com/VictorSanh/Medical_Image_Analysis. Au niveau de la programmation, le code de l'algorithme de segmentation était déjà fourni avec la papier. Victor s'est donc chargé de toute l'intégration des données dans l'algorithme de segmentation, de mener les expérimentations numériques et le calcul des scores. Adèle a manipulé les données de la base de segmentation de Berkeley, et programmé la génération aléatoires des labels utilisateurs à distance constante des contours provenant des vrais labels, et enfin Margot a manipulé les données de ventricule ainsi que de scans, et codé l'algorithme de pré-traitement par seuillage.

Images supplémentaires





FIGURE 9: Autre exemple de segmentation du ventricule gauche



(a) Radiographie de la main




(b) Pre-segmentation de la main par seuillage




(c) Segmentation finale obtenue avec le pre-traitement par seuillage


FIGURE 10: Autre exemple de segmentation avec le pre-traitement par seuillage




(a) Labels utilisateurs à distance 5 (distance de Manhattan) de la limite entre la région Ω_0 de l'objet et l'arrière plan Ω_1



(b) Segmentation correspondant aux labels à distance 5 du contour.



(c) Labels utilisateurs à distance 45 (distance de Manhattan) de la limite entre la région Ω_0 de l'objet et l'arrière plan Ω_1



(d) Segmentation correspondant aux labels à distance 45 du contour.

FIGURE 11: Segmentation en utilisant des labels à différentes distances du contour recherché. Lorsque les labels sont trop proches, les contours sont presque correct, mais loin de ces labels utilisateurs des erreurs apparaissent. Lorsque ces labels sont trop loin l'algorithme a du mal à bien délimiter les régions recherchées.